

Proyecto Final de Inteligencia Artificial

PathForge

Explorador de Universos Profesionales mediante Búsqueda Multiobjetivo y Simulación Estocástica

Estudiante: Josué Javier Senarega Claro
Grupo: C-311

Universidad de La Habana
Facultad de Matemática y Computación
Curso 2025 - 2026

1. Descripción del Problema

1.1 Contexto

La planificación profesional constituye uno de los procesos decisionales más complejos a los que se enfrenta un individuo a lo largo de su vida. A diferencia de problemas de optimización clásica donde las variables y restricciones son bien definidas, el desarrollo de una carrera profesional opera en un espacio decisional altamente incierto, donde las transiciones entre roles dependen de factores tan diversos como las condiciones del mercado laboral, las competencias adquiridas, el riesgo percibido de cada transición, la demanda sectorial, y eventos estocásticos impredecibles tales como crisis económicas, ascensos inesperados, burnout profesional, o la obsolescencia de habilidades técnicas. El mundo laboral contemporáneo, particularmente en el sector tecnológico, presenta una complejidad creciente: la diversificación de roles, la rápida evolución de las tecnologías, y la interdependencia entre sectores productivos generan un espacio de posibles trayectorias profesionales que es prácticamente imposible de explorar de manera exhaustiva mediante simple introspección o consulta informal.

En este contexto, los profesionales se enfrentan sistemáticamente a preguntas fundamentales para las cuales no disponen de herramientas cuantitativas de soporte: ¿Qué trayectoria profesional maximiza el crecimiento salarial sin incurrir en riesgos excesivos? ¿Qué transiciones de carrera son más robustas ante la volatilidad del mercado? ¿Cómo equilibrar satisfacción personal, estabilidad económica y proyección profesional de manera simultánea? Estas preguntas son intrínsecamente multiobjetivo: no existe una única respuesta óptima, sino un conjunto de soluciones no dominadas que representan diferentes compromisos entre objetivos conflictivos.

1.2 El Problema Específico

El problema central que PathForge se propone resolver es la generación automática, diversa y cualitativamente evaluada de trayectorias profesionales alternativas dentro de un dominio laboral dado, con el objetivo de proporcionar al usuario un panorama informado y cuantitativamente fundamentado de las posibles evoluciones de su carrera. Este problema integra tres desafíos computacionales: (1) la exploración eficiente de un espacio de búsqueda combinatorio, (2) la evaluación multiobjetivo con dominancia de Pareto, y (3) la evaluación estocástica de la robustez de cada trayectoria bajo incertidumbre.

1.3 Relevancia

La resolución de este problema tiene implicaciones significativas tanto a nivel individual como sistémico. A nivel individual, una herramienta como PathForge puede ahorrar años de decisiones subóptimas al revelar trayectorias profesionales que el usuario no consideraría por sesgos cognitivos o falta de información. A nivel

sistémico, la optimización de las trayectorias profesionales puede contribuir a una asignación más eficiente del capital humano en la economía, reduciendo el desajuste entre las competencias disponibles y las demandas del mercado.

Además, desde la perspectiva de la inteligencia artificial aplicada, PathForge representa un caso de estudio representativo de la integración de múltiples técnicas: búsqueda en grafos, optimización multiobjetivo, simulación estocástica y procesamiento de lenguaje natural, cada una contribuyendo una dimensión esencial al sistema final.

2. Modelado Formal

2.1 Entidades y Relaciones

El dominio del problema se modela mediante un grafo dirigido ponderado $G = (V, E, \alpha, \beta)$ donde:

- V es el conjunto finito de nodos, cada uno representando un rol o posición profesional. Cada nodo $v \in V$ posee atributos $\alpha(v) = \{\text{avg_salary}(v), \text{demand}(v), \text{satisfaction}(v), \text{years_experience}(v), \text{type}(v), \text{is_terminal}(v)\}$ que caracterizan cuantitativamente el rol.
- E es el subconjunto de $V \times V$ de aristas dirigidas, donde $(u, v) \in E$ indica la existencia de una transición profesional factible desde el rol u hacia el rol v . Cada arista $e = (u, v)$ posee atributos $\beta(e) = \{\text{transition_years}(e), \text{risk}(e)\}$ que cuantifican el costo y la incertidumbre de la transición.
- Trayectoria profesional: Una trayectoria $T = (v_1, v_2, \dots, v_k)$ es un camino simple en G (sin ciclos) donde $v_i \in V$ para todo i , y $(v_i, v_{i+1}) \in E$ para todo $1 \leq i < k$. La longitud de T es k , y el conjunto de todas las trayectorias factibles desde un nodo fuente s se denota $\Omega(s)$.

2.2 Función de Scoring Multiobjetivo

Para cada trayectoria T , se define una función de scoring compuesta por objetivos a maximizar y costos a minimizar. Los objetivos de maximización son: $\text{salary_growth}(T) = (\text{salario}(v_k) - \text{salario}(v_1)) / \text{salario}(v_1)$, $\text{satisfaction_avg}(T) =$ promedio de satisfacción de los nodos en T , y $\text{demand_avg}(T) =$ promedio de demanda de los nodos en T . Los costos a minimizar son: $\text{risk_avg}(T) =$ promedio de riesgo de las aristas en T , y $\text{total_years}(T) =$ sumatoria de los años de transición de las aristas en T .

Adicionalmente, se computan métricas derivadas de la simulación Monte Carlo: $\text{success_score}(T) =$ proporción de simulaciones donde la trayectoria no experimenta eventos negativos críticos, y $\text{negative_event_rate}(T) =$ frecuencia promedio de eventos negativos por simulación. El sistema calcula también la diversidad como la distancia promedio de Jaccard entre pares de trayectorias, y la

crowding distance en el frente de Pareto como medida de dispersión.

2.3 Dominancia de Pareto y Frente Óptimo

Dado un conjunto de trayectorias evaluadas, se define la relación de dominancia de Pareto: una trayectoria T_1 domina a T_2 ($T_1 > T_2$) si T_1 es estrictamente mejor en al menos un objetivo y no peor en ningún otro. El frente de Pareto $P \subseteq \Omega$ es el subconjunto de trayectorias no dominadas. El sistema asigna rangos de Pareto mediante el algoritmo de clasificación no dominada (non-dominated sorting), donde el rango 0 corresponde al frente óptimo P_0 , el rango 1 al segundo frente, y así sucesivamente. La crowding distance se emplea como criterio de desempate dentro de un mismo rango, favoreciendo soluciones más dispersas en el espacio objetivo.

2.4 Restricciones e Invariantes

El sistema impone restricciones que las trayectorias deben satisfacer durante la generación, implementando un esquema de branch-and-bound donde las ramas que violan restricciones son podadas del espacio de búsqueda. Las restricciones implementadas son las siguientes:

- MaxYearsConstraint: sumatoria de `transition_years(e)` para e en T es menor o igual que Y_max .
- MaxRiskConstraint: `avg_risk(T)` es menor o igual que R_max .
- MinSalaryConstraint: `final_salary(T)` es mayor o igual que S_min .
- PercentileMaxRiskConstraint: `avg_risk(T)` es menor o igual que el percentil P de los riesgos del grafo, con mecanismo de `spread awareness` que relaja automáticamente el umbral cuando el rango de riesgo en el grafo es estrecho (menor que 20 % del máximo).
- PercentileMinSalaryConstraint: `final_salary(T)` es mayor o igual que el percentil P de los salarios del grafo, con `spread awareness` para rangos salariales estrechos (menor que 20 % del máximo).

Un invariante fundamental del sistema es que toda trayectoria devuelta por el generador debe satisfacer la restricción compuesta activa, garantizando que las soluciones presentadas al usuario son factibles con respecto a los criterios definidos.

3. Descripción del Dataset Utilizado

3.1 Origen del Dataset

El dataset principal utilizado por PathForge proviene del proyecto público `Karrierewege_plus`, un repositorio disponible en Hugging Face que contiene datos de transiciones profesionales basados en la clasificación internacional ISCO-3

(International Standard Classification of Occupations). Este dataset proporciona información sobre transiciones observadas entre ocupaciones, incluyendo frecuencias de transición, salarios promedio, niveles de demanda y otros indicadores laborales. La clasificación ISCO-3 garantiza una estructura estandarizada y comparable a nivel internacional, lo que permite la construcción de grafos de carrera coherentes y bien definidos.

3.2 Proceso de Transformación

El dataset crudo fue transformado mediante el script `transform_data.py`, que ejecuta un pipeline de procesamiento con las siguientes etapas fundamentales:

- **Agrupación por sectores amplios:** Las ocupaciones ISCO-3 se agrupan en 20 dominios profesionales coherentes (`software_development`, `healthcare_professionals`, `finance`, `engineering`, etc.) mediante un mapeo manual basado en la estructura jerárquica de la clasificación ISCO.
- **Construcción de grafos dirigidos:** Para cada dominio, se genera un grafo dirigido donde los nodos son ocupaciones y las aristas representan transiciones observadas en los datos con frecuencia mayor o igual a un umbral mínimo.
- **Filtrado de calidad:** Dominios con menos de `MIN_NODES_PER_DOMAIN = 5` nodos o `MIN_EDGES_PER_DOMAIN = 5` aristas son descartados, garantizando que cada grafo tenga suficiente estructura para generar trayectorias significativas.
- **Generación de instancias de prueba:** Para cada dominio, se genera un archivo `instances.json` que define configuraciones de experimento con diferentes nodos fuente y perfiles de restricción.

3.3 Validación de Condiciones

El dataset transformado cumple las condiciones necesarias para el problema definido por varias razones fundamentales. Primero, la cobertura sectorial es amplia: los 20 dominios generados abarcan sectores desde tecnología hasta servicios personales, proporcionando un espacio de prueba diverso. Segundo, la estructura de grafo es completa: cada dominio posee un grafo conectado con rutas factibles entre múltiples pares de nodos, permitiendo la generación de trayectorias de longitud variable. Tercero, los atributos normalizados (salario, riesgo, demanda, satisfacción) están disponibles para todos los nodos y aristas, lo que permite la evaluación multiobjetivo sin valores faltantes.

Adicionalmente, se dispone de un grafo legado (`careers.json`) con 12 nodos del sector tecnológico que sirve como caso de prueba canónico y demostración interactiva. Este grafo, aunque más pequeño, contiene la misma estructura de atributos y permite validar el funcionamiento del algoritmo de manera rápida y reproducible.

4. Diseño del Algoritmo

4.1 Panorama General

PathForge implementa un pipeline de cuatro etapas secuenciales que transforman una consulta del usuario (nodo de inicio + perfil de restricciones) en un conjunto de trayectorias profesionales evaluadas, simuladas y analizadas. Las etapas son: (1) Generación de trayectorias mediante Beam Search con poda por restricciones y dominancia de Pareto, (2) Simulación estocástica Monte Carlo de cada trayectoria, (3) Evaluación multiobjetivo con clasificación de Pareto y ranking, y (4) Análisis cualitativo mediante LLM.

4.2 Entradas y Salidas

Entrada del sistema: Un nodo fuente $s \in V$ (rol de inicio de la carrera), un perfil de restricciones C compuesto por los operadores AND/OR de restricciones elementales, y opcionalmente un nodo destino $t \in V$ como objetivo final.

Salida del sistema: Una lista ordenada de `EvaluatedTrajectory`, cada una conteniendo la secuencia de nodos, el diccionario de scores (9 métricas cuantitativas), el rango de Pareto, la crowding distance, y los resultados de la simulación Monte Carlo.

4.3 Beam Search con Poda por Restricciones

El algoritmo central es una variante de Beam Search que integra dominancia de Pareto en la selección del haz y poda por restricciones en la expansión. El procedimiento opera de la siguiente manera: se mantiene un haz (beam) de tamaño fijo `beam_width` con las mejores trayectorias parciales. En cada iteración, cada trayectoria del haz se expande por todos sus sucesores factibles en el grafo, filtrando aquellos que violan las restricciones activas. Las expansiones válidas se evalúan mediante la función de scoring compuesta:

$$\text{score}(T) = (1 - w) \cdot \text{pareto_score}(T) + w \cdot \text{heuristic_potential}(T)$$

donde $w = 0.3$ es el peso de diversidad, $\text{pareto_score}(T) = 0.7 \cdot (1 / \max(1 + \text{rank}, 1)) + 0.3 \cdot (\text{crowding_distance} / 10)$, y $\text{heuristic_potential}(T) = 0.6 \cdot (\text{salario}(v_{\text{actual}}) / \text{max_salary}) + 0.4 \cdot \min(|\text{demand}(v_{\text{actual}})|, 1)$. El haz se trunca al `beam_width` mejores trayectorias según este score, garantizando un balance entre calidad de Pareto y diversidad exploratoria.

4.4 Simulación Estocástica Monte Carlo

El módulo de simulación implementa un modelo estocástico de carrera profesional que ejecuta N simulaciones (por defecto 50) de cada trayectoria generada. En cada simulación, a medida que el individuo avanza por los nodos de la trayectoria, se generan eventos aleatorios cuyas probabilidades dependen del tipo de nodo y

de los atributos de la arista recorrida. Los eventos modelados incluyen: promoción (aumenta salario), cambio de rol lateral (modifica satisfacción), crisis sectorial (reduce demanda), y burnout (reduce satisfacción). El resultado de la simulación es un `success_score` (proporción de simulaciones sin eventos críticos) y un `negative_event_rate` (frecuencia promedio de eventos adversos), métricas que añaden una dimensión de robustez estocástica a la evaluación puramente determinista del Beam Search.

4.5 Estructuras de Datos

Las estructuras de datos clave utilizadas por el sistema son las siguientes. El grafo de carreras se implementa mediante `networkx.DiGraph`, proporcionando operaciones eficientes de consulta de sucesores y atributos. Las trayectorias se representan como listas ordenadas de identificadores de nodos, encapsuladas en la clase `EvaluatedTrajectory` que almacena los scores y metadatos. Las restricciones se implementan mediante una jerarquía de clases con el patrón `Composite`, permitiendo la composición flexible de restricciones elementales mediante operadores AND y OR. La cola del Beam se implementa como una lista ordenada por score con truncamiento al tamaño del haz.

5. Rol del LLM en el Sistema

5.1 Función Específica

El LLM desempeña un rol estrictamente analítico e interpretativo dentro de la arquitectura de PathForge. No participa en la generación de trayectorias, en el cálculo de scores, ni en las decisiones de búsqueda o poda. Su función se limita a dos tareas de posprocesamiento: (1) Generación de análisis cualitativo: para cada trayectoria generada y evaluada cuantitativamente, el LLM produce un informe narrativo que interpreta los scores en lenguaje natural, identifica fortalezas y debilidades de la trayectoria, y contextualiza los resultados dentro del dominio profesional correspondiente. (2) Interpretación de consultas de usuario: el LLM puede recibir descripciones en lenguaje natural del perfil o los objetivos del usuario y sugerir parámetros de restricción apropiados, aunque esta funcionalidad es secundaria en la implementación actual.

5.2 Integración con el Algoritmo

La integración del LLM sigue un patrón de posprocesamiento cualitativo: el pipeline cuantitativo (generación, evaluación, simulación) se ejecuta completamente de manera determinista antes de que el LLM intervenga. Esto garantiza que los resultados numéricos son reproducibles y no dependen de la variabilidad inherente del modelo de lenguaje. El LLM recibe como entrada un prompt estructurado que contiene los datos cuantitativos de cada trayectoria y produce como salida un texto de análisis que se adjunta a los resultados.

5.3 Justificación del Uso de LLM

La elección de un LLM para el análisis cualitativo se justifica por tres razones fundamentales. Primero, la flexibilidad del lenguaje natural: un usuario puede describir sus objetivos de maneras extremadamente variadas, y un LLM puede interpretar y adaptar estas descripciones a parámetros del sistema sin requerir un formato rígido de entrada. Segundo, la capacidad de contextualización: los datos numéricos por sí solos (crecimiento salarial de 0.248, riesgo de 0.470) son difíciles de interpretar para un usuario no experto; el LLM traduce estas métricas a narrativas comprensibles. Tercero, la escalabilidad del análisis: generar análisis cualitativos manualmente para cada trayectoria en cada dominio sería inviable; el LLM permite escalar esta capacidad a cualquier número de dominios y trayectorias sin intervención humana.

5.4 Arquitectura Multi-Proveedor

El sistema implementa un cliente LLM con cola circular de API keys que soporta 7 proveedores: Gemini, Claude, OpenAI, OpenRouter, Groq, DeepSeek y Mistral. El mecanismo de rotación round-robin con cooldown automático garantiza que, si un proveedor alcanza su límite de tasa (rate limit), el sistema transiciona transparentemente al siguiente sin interrumpir el flujo de análisis. Esta arquitectura proporciona resiliencia ante caídas de servicio y permite distribuir la carga entre múltiples endpoints de manera eficiente.

6. Metodología Experimental

6.1 Variables Independientes

El diseño experimental varía dos factores principales de manera sistemática. El primer factor es la configuración del generador, con cuatro niveles que cruzan dos dimensiones (ancho del haz y profundidad máxima): narrow_shallow (beam_width=5, max_depth=3), narrow_deep (beam_width=5, max_depth=6), wide_shallow (beam_width=20, max_depth=3), y wide_deep (beam_width=20, max_depth=6). El segundo factor es el perfil de restricción, con tres niveles que representan diferentes grados de exigencia: relaxed, moderate y strict.

6.2 Variables Dependientes

Para cada combinación experimental se miden las siguientes métricas de salida: número de trayectorias generadas, tamaño del frente de Pareto, crecimiento salarial promedio, satisfacción promedio, riesgo promedio, diversidad de trayectorias (distancia de Jaccard), success_score de la simulación Monte Carlo, tasa de eventos negativos, tiempo de cómputo, y tasa de factibilidad (porcentaje de configuraciones que generan al menos una trayectoria válida). Estas métricas capturan tanto la calidad de las soluciones como la eficiencia del algoritmo.

6.3 Protocolo Experimental

El protocolo experimental se ejecuta automáticamente mediante el script `run_experiments.py` (o `run_all_domains.py` para procesar todos los dominios de una vez). Por defecto, el sistema recorre los 20 dominios profesionales y, para cada uno, ejecuta todas las combinaciones de configuraciones del generador (4 configuraciones) con los perfiles de restricción definidos en `instances.json` (3 perfiles), resultando en 12 ejecuciones por dominio y un total de 240 ejecuciones experimentales. Cada ejecución genera trayectorias, evalúa la calidad de Pareto, ejecuta la simulación Monte Carlo y, si el LLM está habilitado, produce el análisis cualitativo correspondiente.

Variantes de ejecución disponibles:

- `python backend/experiments/run_experiments.py` → ejecuta todos los dominios.
- `--domain` → ejecuta solo un dominio específico (ej. `--domain engineering`).
- `--no-llm` → desactiva el análisis cualitativo del LLM (más rápido, sin llamadas a API).
- `--quick` → modo rápido: ejecuta solo un dominio representativo y reduce el número de instancias.
- `--help` → muestra la ayuda completa.

El script `run_all_domains.py` es una alternativa que itera automáticamente sobre todos los dominios que posean `graph.json` e `instances.json`, llamando internamente a `run_all_experiments` del módulo `runner` para cada uno de ellos.

6.4 Modelo de Machine Learning

Paralelamente, el sistema integra un modelo de predicción de éxito de transiciones de carrera implementado con `GradientBoostingClassifier` de `scikit-learn`. El modelo se entrena con 2 000 muestras sintéticas generadas a partir de los atributos del grafo (diferencial salarial, diferencia de demanda, riesgo de transición, satisfacción del nodo destino) y alcanza una precisión del 87.5 % en el conjunto de prueba. Este modelo proporciona una estimación adicional de la viabilidad de cada transición profesional, complementando los scores del Beam Search con una perspectiva de aprendizaje automático.

7. Resultados y Análisis

7.1 Visión General por Dominio

La tabla siguiente resume los resultados experimentales agregados por dominio profesional, mostrando las métricas clave promediadas sobre todas las combinaciones de configuración y perfil. Los 20 dominios evaluados abarcan

desde sectores de alta tecnología hasta servicios personales, proporcionando una visión integral del rendimiento del sistema.

Dominio	Tasa Éxito	Diversid ad	Crec. Salarial	Sim Score	Riesgo	Tiempo (ms)
Administration	100 %	1.060	0.111	0.794	0.464	84.6
Agriculture	100 %	1.137	0.231	0.804	0.469	128.1
Arts & Design	83.3 %	0.948	0.061	0.818	0.448	12.7
Construction	100 %	1.074	0.092	0.823	0.455	307.4
Education	100 %	1.142	0.062	0.829	0.453	82.0
Electrical Eng.	91.7 %	1.072	0.304	0.810	0.461	51.8
Energy & Mining	91.7 %	1.041	0.142	0.818	0.455	26.9
Engineering	100 %	1.108	0.096	0.789	0.462	19.2
Eng. Technology	100 %	1.111	0.095	0.806	0.462	287.5
Finance	100 %	1.095	0.171	0.769	0.465	259.3
Healthcare Prof.	100 %	1.065	0.221	0.821	0.462	16.2
Healthcare Tech.	100 %	0.656	0.115	0.828	0.467	4.2
Hospitality	100 %	1.098	0.280	0.779	0.472	93.9
Legal & Social	91.7 %	1.081	0.260	0.777	0.465	94.3
Logistics & Transp.	100 %	1.126	0.056	0.825	0.460	68.2
Personal Services	100 %	1.061	0.111	0.830	0.456	105.4
Protective Serv.	100 %	1.343	0.243	0.797	0.479	9.3
Retail & Sales	100 %	1.114	0.073	0.821	0.459	379.1
Science	91.7 %	1.063	0.229	0.790	0.466	153.5
Software Dev.	100 %	1.084	0.248	0.758	0.470	101.7

Tabla 1: Resumen de resultados experimentales por dominio profesional.

Los resultados revelan patrones interesantes. Los dominios con mayor crecimiento salarial promedio son `electrical_engineering` (0.304), `hospitality` (0.280), `legal_social` (0.260) y `software_development` (0.248), lo cual es consistente con sectores que presentan una amplia gama de niveles salariales. Por otro lado, los dominios con mayor diversidad de trayectorias son `protective_services` (1.343), `agriculture` (1.137) y `education` (1.142), indicando mayor variedad en las rutas profesionales generadas. La tasa de factibilidad es del 100 % en 16 de los 20 dominios, lo que demuestra que el algoritmo es capaz de encontrar trayectorias válidas en la gran mayoría de los casos.

7.2 Análisis de Simulación Monte Carlo

La simulación Monte Carlo proporciona una dimensión de robustez estocástica que no es capturada por las métricas deterministas del Beam Search. El `success_score` promedio oscila entre 0.758 (`software_development`) y 0.830 (`personal_services`), lo que indica que, en general, entre el 75 % y el 83 % de las simulaciones de cada trayectoria no experimentan eventos negativos críticos. Este rango, aunque razonablemente alto, sugiere que existe un margen significativo de incertidumbre que debe ser considerado en la toma de decisiones.

Se observa una correlación inversa entre `success_score` y riesgo de eventos negativos: los dominios con mayor volatilidad (`software_development`, `finance`) muestran menores scores simulados pero mayor variabilidad en los resultados, lo cual es consistente con la naturaleza cíclica y competitiva de estos sectores. La figura siguiente muestra la comparativa visual de los resultados agregados por dominio.




Figura 1: Visión general de resultados experimentales por dominio profesional.

Como se observa en la Figura 1, los dominios como `personal_services` y `healthcare_technicians` presentan los mayores `success_score`, mientras que `software_development` y `finance` exhiben mayor volatilidad pero también mayor potencial de crecimiento salarial. Este patrón refleja la compensación fundamental entre estabilidad y rendimiento que caracteriza la planificación profesional multiobjetivo.

La Figura 2 presenta el análisis detallado de la simulación Monte Carlo, mostrando la distribución de success score y negative event rate por dominio.




Figura 2: Análisis de simulación Monte Carlo por dominio profesional.

La simulación revela que los dominios con mayor riesgo promedio (protective_services con 0.479, hospitality con 0.472) no necesariamente presentan los menores success_score, lo que sugiere que el modelo de eventos estocásticos captura matices que un análisis puramente basado en riesgo promedio no reflejaría. La relación entre riesgo y éxito simulado es compleja y no lineal, lo que subraya la importancia de la simulación como complemento de la evaluación determinista.

7.3 Comparación Cruzada de Configuraciones

La comparación entre configuraciones del generador revela que el ancho del haz (beam_width) es el factor con mayor impacto en la diversidad de las trayectorias generadas. Las configuraciones wide (beam_width=20) producen consistentemente mayor diversidad que las narrow (beam_width=5), con un incremento promedio del 30 % en la distancia de Jaccard. Sin embargo, este aumento en diversidad no siempre se traduce en mejor calidad de Pareto: las configuraciones narrow_deep frecuentemente encuentran trayectorias con mejor crecimiento salarial y menor riesgo, aunque menos variadas.




Figura 3: Comparación cruzada de configuraciones experimentales.

Como se ilustra en la Figura 3, las configuraciones wide_deep (beam_width=20, max_depth=6) representan el mejor compromiso entre diversidad y calidad, generando el mayor número de trayectorias en el frente de Pareto con un incremento moderado en el tiempo de cómputo. Por el contrario, las configuraciones narrow_shallow son más eficientes temporalmente pero producen trayectorias menos diversas y con menor cobertura del espacio objetivo.

7.4 Casos de Estudio

7.4.1 Caso de Éxito: Software Development

El dominio software_development representa un caso de éxito del sistema. Con 100 % de tasa de factibilidad, el algoritmo genera trayectorias con crecimiento salarial promedio de 24.8 % y diversidad de 1.084, indicando que el grafo de este dominio ofrece múltiples rutas profesionales viables con buen potencial de crecimiento. Sin embargo, el success_score más bajo (0.758) entre todos los dominios refleja la alta volatilidad inherente al sector tecnológico, donde las transiciones de carrera están sujetas a mayor incertidumbre.

7.4.2 Caso Desafiante: Healthcare Technicians

El dominio healthcare_technicians presenta el menor tiempo de cómputo (4.15 ms en promedio) y la menor diversidad (0.656), pero la mayor tasa de llegada a nodos terminales (61.06 %). Esto se explica por la estructura particular de su grafo: pocas aristas de transición pero conectividad suficiente para generar trayectorias cortas y eficientes hacia posiciones terminales. El bajo riesgo promedio (0.467) y el alto success_score (0.828) indican que este sector, aunque limitado en opciones de transición, ofrece trayectorias estables y predecibles.

8. Limitaciones y Posibles Mejoras

8.1 Limitaciones del Trabajo Actual

8.1.1 Dependencia del Dataset Fuente

El dataset `Karrierewege_plus`, aunque público y basado en clasificaciones internacionales, refleja predominantemente el mercado laboral europeo. Las trayectorias, salarios y demandas pueden no ser representativos de mercados emergentes o regiones con estructuras laborales diferentes. Adicionalmente, los datos de satisfacción profesional no están directamente disponibles en la fuente original y fueron estimados mediante heurísticas basadas en atributos parciales, lo que introduce una fuente de incertidumbre adicional en las evaluaciones del sistema.

8.1.2 Escalabilidad en Grafos de Gran Tamaño

El Beam Search con poda por restricciones tiene complejidad exponencial en el peor caso. Si bien la poda y el ancho del haz limitan la explosión combinatoria, dominios con grafos muy grandes (más de 100 nodos) pueden experimentar tiempos de cómputo significativos, especialmente con configuraciones `wide_deep`. Los resultados muestran tiempos de hasta 379 ms para `retail_sales`, lo que aunque aceptable para procesamiento por lotes, podría ser problemático para aplicaciones interactivas en tiempo real.

8.1.3 Modelo de Eventos Estocásticos Simplificado

La simulación Monte Carlo utiliza probabilidades de eventos fijas por tipo de nodo y ajustes lineales basados en satisfacción y demanda. Este modelo, aunque funcional, no captura interacciones entre eventos ni dependencias temporales: un evento de crisis sectorial no afecta la probabilidad de eventos subsecuentes, y el impacto del burnout es independiente del historial previo del individuo. Un modelo más realista requeriría cadenas de Markov con estado completo o redes bayesianas dinámicas.

8.1.4 Análisis del LLM No Determinista

Las respuestas del LLM son inherentemente no deterministas: la misma consulta puede generar análisis diferentes en ejecuciones sucesivas, incluso con temperatura baja (0.3). Si bien esto es aceptable para un sistema de orientación, limita la reproducibilidad experimental de los análisis cualitativos. Además, la calidad del análisis depende del proveedor de LLM seleccionado, introduciendo una variable no controlada en el pipeline de resultados.

8.2 Posibles Mejoras

8.2.1 Expansión del Dataset

Ampliar el dataset con datos de mercados laborales adicionales (BLS, Eurostat, encuestas regionales) permitiría al sistema ofrecer análisis más representativos a

nivel global. La integración de datos temporales (tendencias de demanda por año) habilitaría la generación de trayectorias adaptativas que ajusten sus recomendaciones según las proyecciones del mercado futuro, proporcionando una orientación más dinámica y contextualizada.

8.2.2 Mejoras Algorítmicas

Implementar algoritmos de búsqueda más sofisticados como A* multiobjetivo con heurísticas admisibles podría mejorar la eficiencia del generador en grafos grandes. La integración de técnicas de sampling estocástico en la fase de expansión del haz añadiría diversidad exploratoria sin sacrificar la calidad de Pareto, permitiendo escapar de óptimos locales en el espacio de trayectorias.

8.2.3 Fine-tuning del LLM

Realizar ajuste fino (fine-tuning) de un modelo de lenguaje con datos específicos del dominio de orientación profesional mejoraría la precisión y relevancia de los análisis. Un modelo fine-tuneado podría generar recomendaciones más contextualizadas y reducir la variabilidad entre ejecuciones, al tiempo que disminuiría la dependencia de múltiples proveedores externos.

8.2.4 Modelo de Simulación Enriquecido

Desarrollar un modelo de simulación basado en cadenas de Markov con estado completo, donde la probabilidad de cada evento depende del historial completo de la trayectoria y los eventos previos, proporcionaría evaluaciones de robustez más realistas. La incorporación de correlaciones entre eventos (por ejemplo, que una crisis sectorial incremente la probabilidad de burnout) capturaría dinámicas que el modelo actual no representa, enriqueciendo significativamente la capacidad predictiva del sistema.

*«El mapa de nuestra carrera no está trazado en la roca, sino en la arena de la decisión.
Cada elección bien informada es una brújula que nos acerca, un paso más, a la versión de
nosotros mismos que aún no conocemos.»*

Repositorio del Proyecto:
<https://github.com/JosuSC/PathForge>